بسمه تعالى

این دیتاست شامل متونی از شبکهاجتماعی توییتر است و در صورت سوال خواسته شده که توییتها را به دو دسته افراز کنیم. دسته اول شامل توییتهای میشود که دارای مفاهیم تبعیض جنسیتی و نژادپرستی میباشد. اما دسته دوم توییت هایی را شامل میشود که عضو دسته اول نباشند.

پس از انجام پیشپردازشهای مورد نظر، دادگان را به دو دسته تقسیمبندی کردم که برچسب ۱ مربوط به مطالب نژادپرستانه و برچسب ۰ نشان دهنده مطالب عاری از نژادپرستی و تبعیض جنسیتی است. نتیجه این مدل را در زیر مشاهده می کنید:

	precision	recall	f1-score	support
0.0 1.0	0.96 0.73	0.99 0.37	0.97 0.49	8939 650
accuracy macro avg weighted avg	0.84 0.94	0.68 0.95	0.95 0.73 0.94	9589 9589 9589

زمان مصرفی در این حالت به شرح زیر است:

preprocessing: 7.65 seconds •

train: 13.28 seconds •

predict: 1 second •

در ادامه با استفاده از یادگیری بینظارت (الگوریتم Kmeans) مسئله را به روش نیمهنظارت شده (semi supervised) نیز مورد بررسی قراردادم .

ابتدا تعداد بهینه دسته هایی که میتوان دادگان را در آنها خوشهبندی کرد، بدست آوردم، سپس با استفاده از برچسبهای جدید الگوریتم دستهبندی را اجرا کردم.

نتایج این رویکرد را در تصویر پایین مشاهده می کنید:

		. 525 (عدین این روی در در حصویر پایین مستعدد سی حدید .		
	precision	recall	f1-score	support	
0 1 2 3 4	0.94 0.93 0.92 0.94 0.99	0.95 0.92 0.94 0.93 0.94	0.94 0.93 0.93 0.93 0.96	3214 1385 1775 2919 296	
accuracy macro avg weighted avg	0.94 0.93	0.93 0.93	0.93 0.94 0.93	9589 9589 9589	

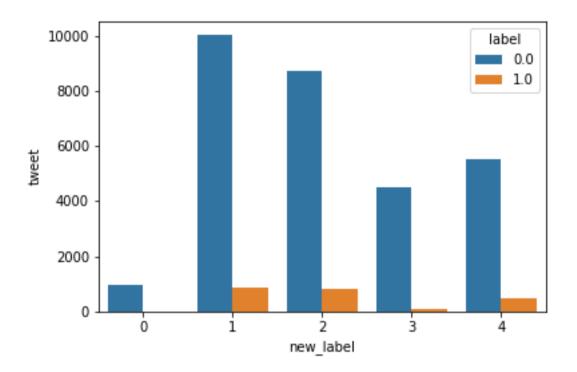
زمان مصرفی در این روش به شرح زیر است:

preprocessing: 9.11 seconds •

train: 50.31 seconds

predict: 1.5 seconds

در نهایت تصویر زیر نشان دهنده تعداد توییتهای مربوط به ۵ کلاس جدید به تفکیک ۲ کلاس قبلی است:



طبق این تصویر، بیشترین توییتهای نژادپرستانه به تریتب مربوط به کلاس ۱، ۲ و ۴ است.